

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА»

ФИЗИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА ОБЩЕЙ ФИЗИКИ И МОЛЕКУЛЯРНОЙ ЭЛЕКТРОНИКИ

БАКАЛАВРСКАЯ РАБОТА

**«МОДЕЛИРОВАНИЕ РАСПОЗНАВАНИЯ ОБРАЗОВ
НА ОСНОВЕ ИСПУЛЬСНЫХ НЕЙРОННЫХ СЕТЕЙ С
КОНКУРЕНЦИЕЙ ЛОКАЛЬНЫХ РЕЦЕПТИВНЫХ
ПОЛЕЙ»**

Выполнил студент:
406 группа
Гафни Д.

подпись студента

Научный руководитель:
Королёва А.В.

подпись научного руководителя

Научный консультант:
Дёмин В.А.

подпись научного консультанта

Допущена к защите
Зав.кафедрой _____

подпись зав.кафедрой

Москва

2020

Содержание

1	Введение	2
1.1	Мотивация	3
1.2	Постановка задачи	3
1.3	Спайковая нейронная сеть	3
1.4	Локально соединенная архитектура	5
2	Методика	6
3	Сравнение архитектур	6
4	Обучение конкуренции	8
5	Вывод	8

1 Введение

Импульсные (спайковые) нейронные сети (СНС) являются перспективным нейроморфным алгоритмом, биологически корректно моделируя взаимодействия нейронов мозга. Наибольший интерес СНС представляют для решения задач в реальном времени (принятие решений, распознавание образов), так как могут быть реализованы на специализированном вычислительно- и энергоэффективном мемристорном нейрочипе. В отличие от формальных нейронных сетей, в спайковых сетях нейроны обмениваются дискретными электрическими сигналами (спайками), существующими во времени. При накоплении потенциала, превышающего определенный порог активации, нейрон сам испускает спайк. Влияние входящих спайков на потенциал нейрона определяется значением веса межнейронной связи. Этим процессам соответствуют аналогичные физические явления в реальных мемристорных сетях.

Стандартные методы обучения весов связей, применяющиеся в формальных нейронных сетях (метод обратного распространения ошибки) не представляется возможным применять к СНС из-за их дискретной и распределенной во времени природы. Таким образом, исследование алгоритмов обучения СНС представляется важной задачей.

В данной работе изучается влияние обучения связей конкуренции [1] [2] между нейронами на точность распознавания образов в задаче классификации рукописных изображений цифр (MNIST) при обучении без учителя для архитектуры локально соединенной сети (Locally Connected Spiking Neural Network, LCSNN) [3], а также проводится сравнение этой архитектуры со сверточной сетью (Convolution Spiking Neural Network, CSNN) и полносвязной сетью (Fully Connected Spiking Neural Network, FCSNN). Обучение производится в соответствии с правилом STDP, используется модель интегрирующих нейронов с утечкой. Все параметры моделей задаются в соответствии с достигаемыми значениями в реальных мемристорах.

1.1 Мотивация

Недостатки формальных нейронных сетей Современные формальные нейронные сети отлично справляются со многими задачами машинного обучения. Однако их обучение - трудоемкий процесс, требующий больших вычислительных ресурсов. Обычно обучение ведется на десятках и сотнях тысячах примеров и может занимать месяцы. Как само обучение, так и последующее применение формальных нейросетевых алгоритмов далеки от эффективности. Это связано как с физически раздельным хранением значений весов и активаций нейронов, так и с самими вычислениями, которые носят тензорный характер. Современные процессоры не оптимизированы для подобных вычислений. Вместо них используются GPU - архитектуры, изначально созданные для работы с компьютерной графикой, а потому лучше подходящие для тензорных вычислений, однако и они не дают желаемого результата. Например, типичное время распознавание лица современными алгоритмами - 200-300 мс.

Плюсы спайковых нейронных сетей В отличие от формальных, спайковые нейронные сети:

- могут быть реализованы на специализированном сверхэффективном нейроморфном процессоре
- биологически корректно моделируют взаимодействия нейронов

Описание нейрочипа *Почему биологическая корректность это хорошо*

1.2 Постановка задачи

- Сравнить локально соединенную сеть со сверточной и полносвязной сетью
- Исследовать конкуренцию

1.3 Спайковая нейронная сеть

Устройство нейронной сети Нейроны там есть всякие спайки

Обучение по правилу STDP STDP - Spike Timing Dependent Plasticity - биологически инспирированное правило обучения без учителя.

$$\Delta w = A \cdot e^{-\frac{t_{pre} - t_{post}}{\tau}} \quad (1)$$




Рис. 1: Правило STDP. График зависимости изменения веса от разности времени регистрации пост- и пре- спайков.

1.4 Локально соединенная архитектура

Эта нейросетевая архитектура вдохновлена строением зрительной коры мозга. В отличие от сверточной сети, ее нейроны не имеют общих весов, которые потому и называются локальными. На иллюстрации ниже показано строение локально соединенной сети.




Рис. 2: Схема архитектуры LCSNN

Нейроны, имеющие общие рецептивные поля дополнительно соединяются связями конкуренции. Такие связи имеют отрицательные веса, а значит, негативно влияют на активность. Заметим, что нейроны, не имеющие общего рецептивного поля (а значит, реагирующие на разные области изображения) не конкурируют между собой.

LCSNN отличаются большой скоростью обучения. Через несколько тысяч итераций точность распознавания выходит на плато насыщения, после чего уже не возрастает.

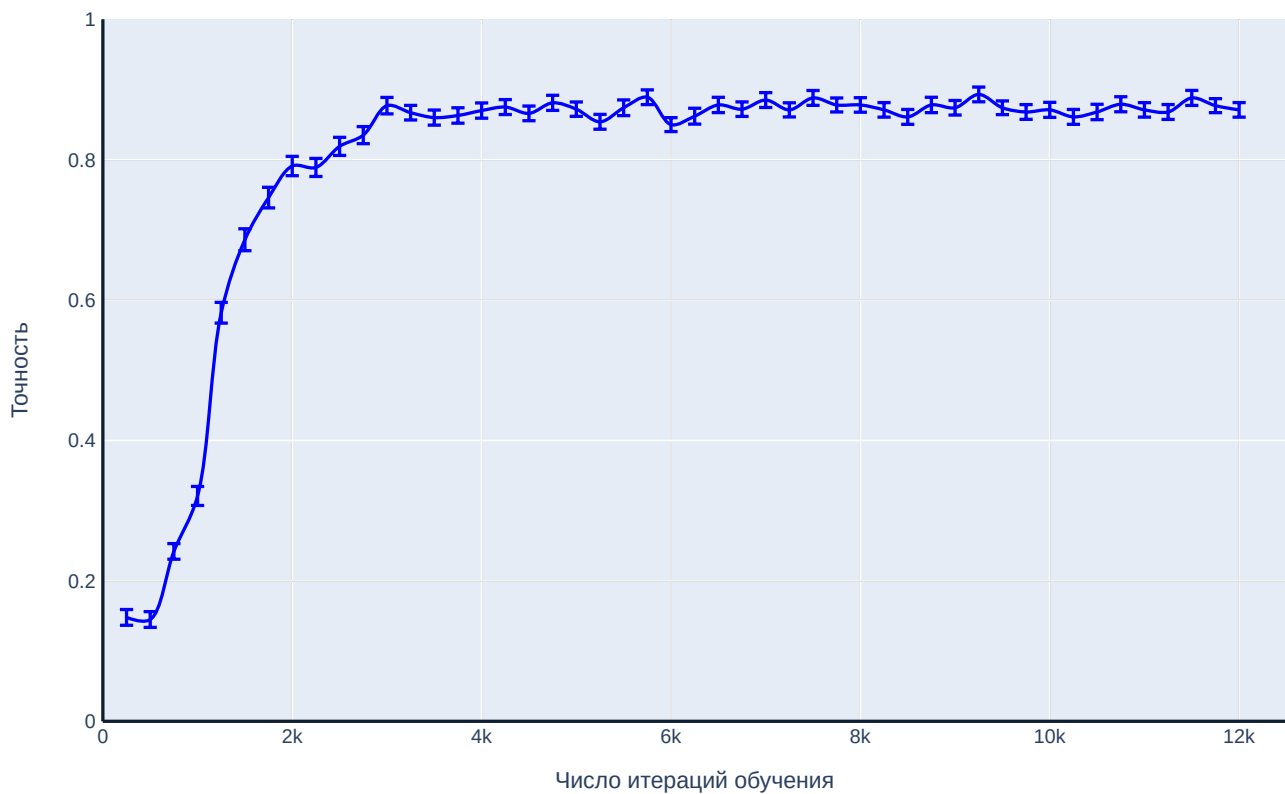


Рис. 3: Скорость обучения LCSNN

2 Методика

Во всех экспериментах используются модель интегрирующих нейронов с утечкой.

Вставить формулу

3 Сравнение архитектур

Результаты экспериментов с различными архитектурами

Архитектура	Фильтры	Ядро	Веса	Нейроны	Точность	Погрешность
LCSNN	100	12	449100	900	0.8752	0.0090
LCSNN	100	8	798400	1600	0.8285	0.0021
LCSNN	25	12	95400	225	0.7939	0.0038
LCSNN	25	8	169600	400	0.7360	0.0103
CSNN	100	8	11350	1600	0.7736	0.0188
CSNN	25	12	3900	225	0.6577	0.0067
CSNN	25	8	1900	400	0.5807	0.0117
FCSNN	100	20	44950	100	0.7340	0.0866




Рис. 4: Веса XY слоя после обучения

4 Обучение конкуренции

5 Вывод

Список литературы

- [1] Vyacheslav Demin и Dmitry Nekhaev. “Recurrent Spiking Neural Network Learning Based on a Competitive Maximization of Neuronal Activity”. в: *Frontiers in Neuroinformatics* 12 (нояб. 2018), с. 79. DOI: [10.3389/fninf.2018.00079](https://doi.org/10.3389/fninf.2018.00079).
- [2] Dmitry Nekhaev и Vyacheslav Demin. “Competitive Maximization of Neuronal Activity in Convolutional Recurrent Spiking Neural Networks”. в: янв. 2020, с. 255—262. ISBN: 978-3-030-30424-9. DOI: [10.1007/978-3-030-30425-6_30](https://doi.org/10.1007/978-3-030-30425-6_30).
- [3] Daniel J. Saunders и др. *Locally Connected Spiking Neural Networks for Unsupervised Feature Learning*. 2019. arXiv: [1904.06269](https://arxiv.org/abs/1904.06269) [[cs.NE](#)].