

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА»

ФИЗИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА ОБЩЕЙ ФИЗИКИ И МОЛЕКУЛЯРНОЙ ЭЛЕКТРОНИКИ

БАКАЛАВРСКАЯ РАБОТА

**«МОДЕЛИРОВАНИЕ РАСПОЗНАВАНИЯ ОБРАЗОВ
НА ОСНОВЕ ИМПУЛЬСНЫХ НЕЙРОННЫХ СЕТЕЙ С
КОНКУРЕНЦИЕЙ ЛОКАЛЬНЫХ РЕЦЕПТИВНЫХ
ПОЛЕЙ»**

Выполнил студент:
406 группа
Гафни Д.

подпись студента

Научный руководитель:
Королёва А.В.

подпись научного руководителя

Научный консультант:
Дёмин В.А.

подпись научного консультанта

Допущена к защите
Зав.кафедрой _____

подпись зав.кафедрой

Москва

2020

Содержание

1	Введение	3
1.1	Мотивация	3
1.2	Постановка задачи	3
2	Спайковые нейронные сети	4
2.1	Преимущества спайковых нейронных сетей	4
2.2	Модели нейронов спайковой нейронной сети	4
2.2.1	Интегратор с утечкой и адаптивным порогом	4
2.3	Архитектуры спайковых нейронных сетей	6
2.4	Алгоритмы обучения спайковых нейронных сетей	6
2.5	Современные реализации спайковых нейронных	6
3	Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей	7
3.1	Описание задачи классификации	7
3.2	Особенности архитектуры	7
3.3	Сравнение эффективности операции свертки и локального рецептивного поля	8
3.4	Обучение связей конкуренции спайковой нейронной сети	10
3.5	Выводы	10
4	Заключение	11
5	Благодарности	12

1 Введение

Импульсные (спайковые) нейронные сети (СНС) являются перспективным нейроморфным алгоритмом, биологически корректно моделируя взаимодействия нейронов мозга. Наибольший интерес СНС представляют для решения задач в реальном времени (принятие решений, распознавание образов), так как могут быть реализованы на специализированном вычислительно- и энергоэффективном мемристорном нейрочипе, так как

Стандартные методы обучения весов связей, применяющиеся в формальных нейронных сетях (метод обратного распространения ошибки) не представляется возможным применять к СНС из-за их дискретной и распределенной во времени природы. Таким образом, исследование алгоритмов обучения СНС представляется важной задачей.

1.1 Мотивация

Недостатки формальных нейронных сетей Современные формальные нейронные сети отлично справляются со многими задачами машинного обучения [4]. Однако их обучение - трудоемкий процесс, требующий больших вычислительных ресурсов. Обычно обучение ведется на десятках и сотнях тысячах примеров и может занимать месяцы. Как само обучение, так и последующее применение формальных нейросетевых алгоритмов далеки от эффективности. Это связано как с физически раздельным хранением значений весов и активаций нейронов, так и с самими вычислениями, которые носят тензорный характер. Современные процессоры не оптимизированы для подобных вычислений. Гораздо лучше процессоров для этих задач подходят GPU - архитектуры, изначально созданные для работы с компьютерной графикой, а потому лучше подходящие для тензорных вычислений, однако и они не дают желаемого результата. Например, типичное время распознавание лица современными алгоритмами - 200-300 мс.

1.2 Постановка задачи

В данной работе:

1. Изучается влияние обучения связей конкуренции [1] [2] между нейронами на точность распознавания образов в задаче классификации рукописных изображений цифр (MNIST) при обучении без учителя для архитектуры локально соединенной сети (Locally Connected Spiking Neural Network, LCSNN) [3]
2. Проводится сравнение этой архитектуры со сверточной сетью (Convolution Spiking Neural Network, CSNN) и полносвязной сетью (Fully Connected Spiking Neural Network, FCSNN).

2 Спайковые нейронные сети

Спайковая нейронная сеть - модель нейронной сети, которая состоит из отдельных нейронов и связей между ними. Каждый нейрон имеет свой виртуальный потенциал, а каждая связь имеет некоторый вес. Нейроны обмениваются дискретными электрическими сигналами (спайками), имеющими очень короткую (≈ 1 мс) длительность. Влияние входящих спайков на потенциал нейрона определяется значением веса межнейронной связи. При накоплении потенциала, превышающего определенный порог активации, нейрон сам испускает спайк, а после сбрасывает свой напряжение до некоторого уровня релаксации. При запуске сети активность некоторых входных нейронов задается определенным образом, после чего проводится симуляция на протяжении некоторого времени (≈ 250 мс), много большего длительности спайка.

2.1 Преимущества спайковых нейронных сетей

В отличие от формальных, спайковые нейронные сети:

- могут быть реализованы на специализированном сверхэффективном нейроморфном процессоре
- биологически корректно моделируют взаимодействия нейронов

Ней *Почему биологическая корректность это хорошо*

2.2 Модели нейронов спайковой нейронной сети

Реальный нейрон мозга является очень сложным объектом, поведение которого до сих пор не до конца изучено. Для спайковых нейронных сетей используются упрощенные модели нейронов. Перечислим некоторые из них.

2.2.1 Интегратор с утечкой и адаптивным порогом

В данной работе используется модель адаптивного “Интегрировать-и-сработать” нейрона с утечкой (Adaptive Leaky Integrate-And-Fire, ALIF). В этой модели динамика потенциала задается следующим уравнением:

$$\tau_v \frac{dv(t)}{dt} = -v(t) + v_{rest} + I(t), \quad (1)$$

где $I(t)$ - ток, накопившийся в нейроне к моменту времени t , v_{rest} - уровень релаксации, τ_v - временная константа симуляции.

Таким образом, потенциал нейрона сам по себе стремится вернуться в состояние релаксации, так как если $I(t) = 0$ (нет входящих спайков) и $v(t) = v_{rest}$, то производная $\frac{dv(t)}{dt} = 0$, то есть потенциал нейрона будет оставаться постоянным на уровне v_{rest} .

Порог активации v_{thresh} у ALIF нейрона не является константой, а немного повышается при каждом спайке, релаксируя затем к своему начальному значению. Динамика порога активации задается следующими уравнениями:

$$v_{thresh} = \theta_0 + \theta(t), \quad (2)$$

где θ_0 - начальный порог активации, $\theta(t)$ - адаптивная добавка, которая вычисляется из условия

$$\tau_v \frac{d\theta(t)}{dt} = -\theta(t) \quad (3)$$

Таким образом, порог активации нейрона сам по себе стремится вернуться к начальному значению, так как при $\theta(t) = \theta_0$, то производная $\frac{d\theta(t)}{dt} = 0$, то есть порог активации нейрона будет оставаться постоянным на уровне θ_0 .

После испускания каждого спайка порог активации повышается на θ_{plus} .

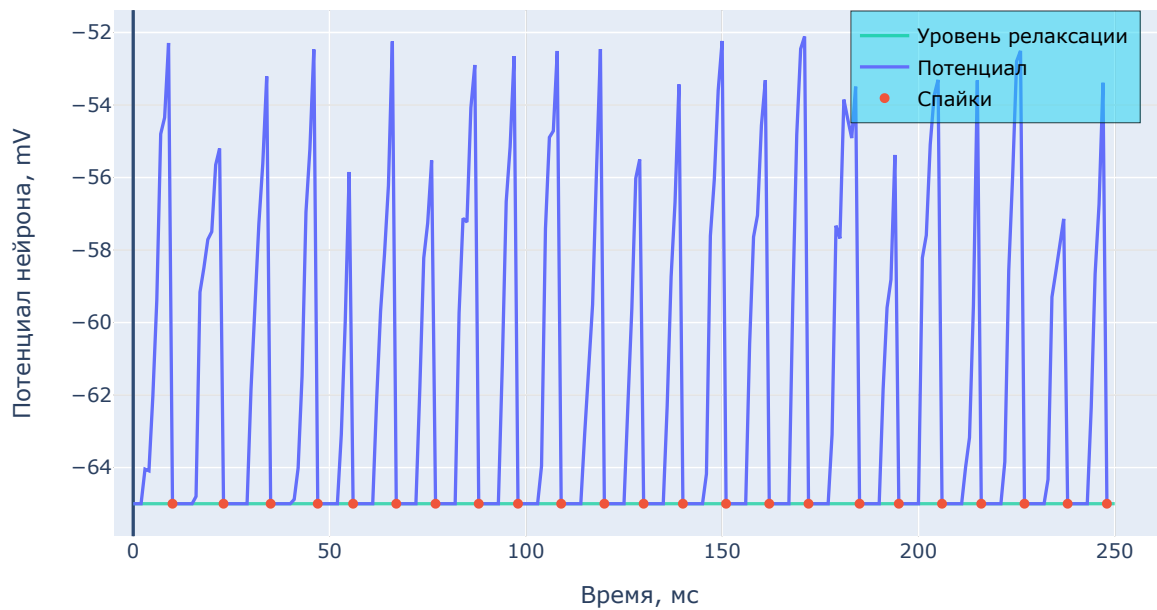


Рис. 1: Динамика потенциала нейрона. Красными точками отмечены моменты времени, когда нейрон испускает спайк и сбрасывает свой потенциал до уровня релаксации.

2.3 Архитектуры спайковых нейронных сетей

Архитектуры

2.4 Алгоритмы обучения спайковых нейронных сетей

STDP - Spike Timing Dependent Plasticity - биологически инспирированное правило обучения без учителя.

$$\Delta w = \begin{cases} A_+ \cdot e^{-\frac{t_{pre}-t_{post}}{\tau_+}}, & t_{pre} - t_{post} > 0 \\ A_- \cdot e^{-\frac{t_{pre}-t_{post}}{\tau_-}}, & t_{pre} - t_{post} < 0 \end{cases} \quad (4)$$

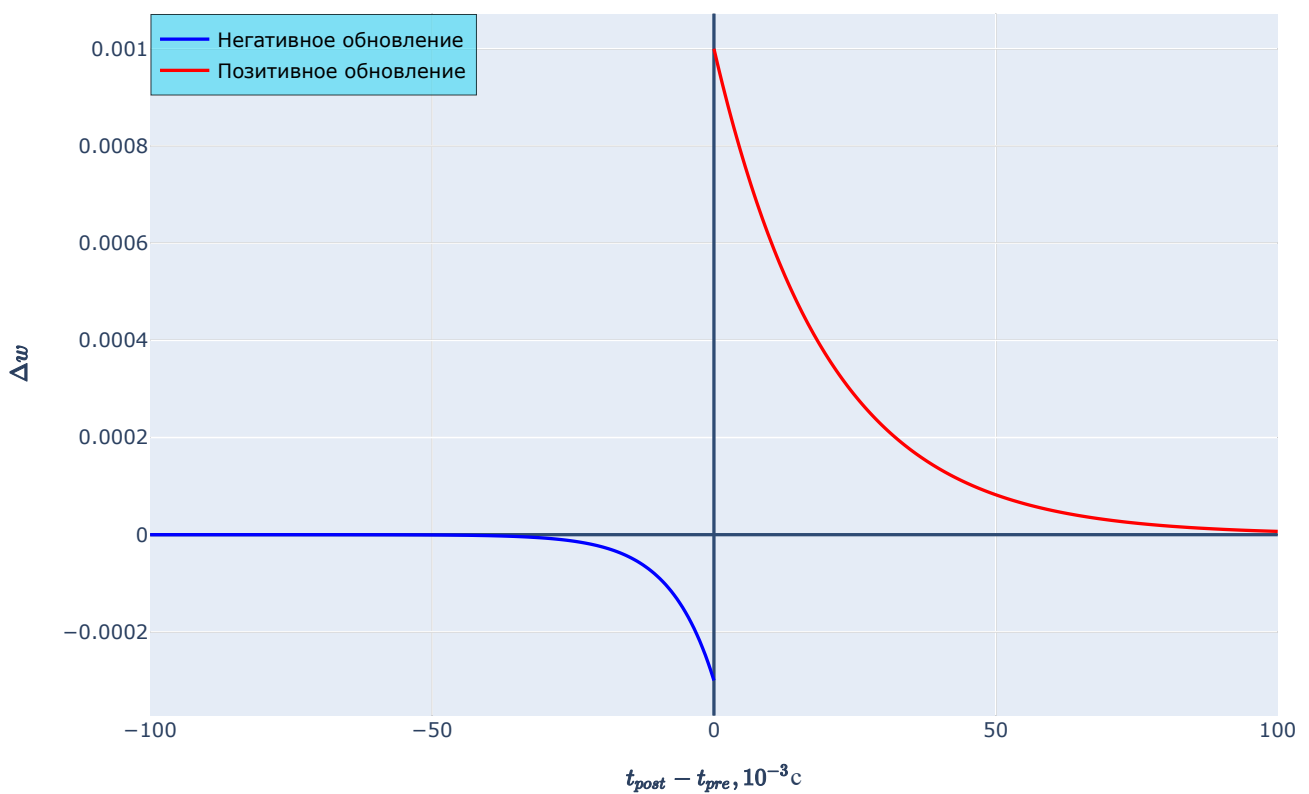


Рис. 2: Правило STDP. График зависимости изменения веса от разности времени регистрации пост- и пре-спайков.

2.5 Современные реализации спайковых нейронных

Современные реализации

3 Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей

3.1 Описание задачи классификации

Описание задачи

3.2 Особенности архитектуры

Эта нейросетевая архитектура вдохновлена строением зрительной коры мозга. В отличие от сверточной сети, ее нейроны не имеют общих весов, которые потому и называются локальными. На иллюстрации ниже показано строение локально соединенной сети.




Рис. 3: Схема архитектуры LCSNN

Нейроны, имеющие общие рецептивные поля дополнительно соединяются связями конкуренции. Такие связи имеют отрицательные веса, а значит, негативно влияют на активность. Заметим, что нейроны, не имеющие общего рецептивного поля (а значит, реагирующие на разные области изображения) не конкурируют между собой.

LCSNN отличаются большой скоростью обучения. Через несколько тысяч ите-

раций точность распознавания выходит на плато насыщения, после чего уже не возрастает.

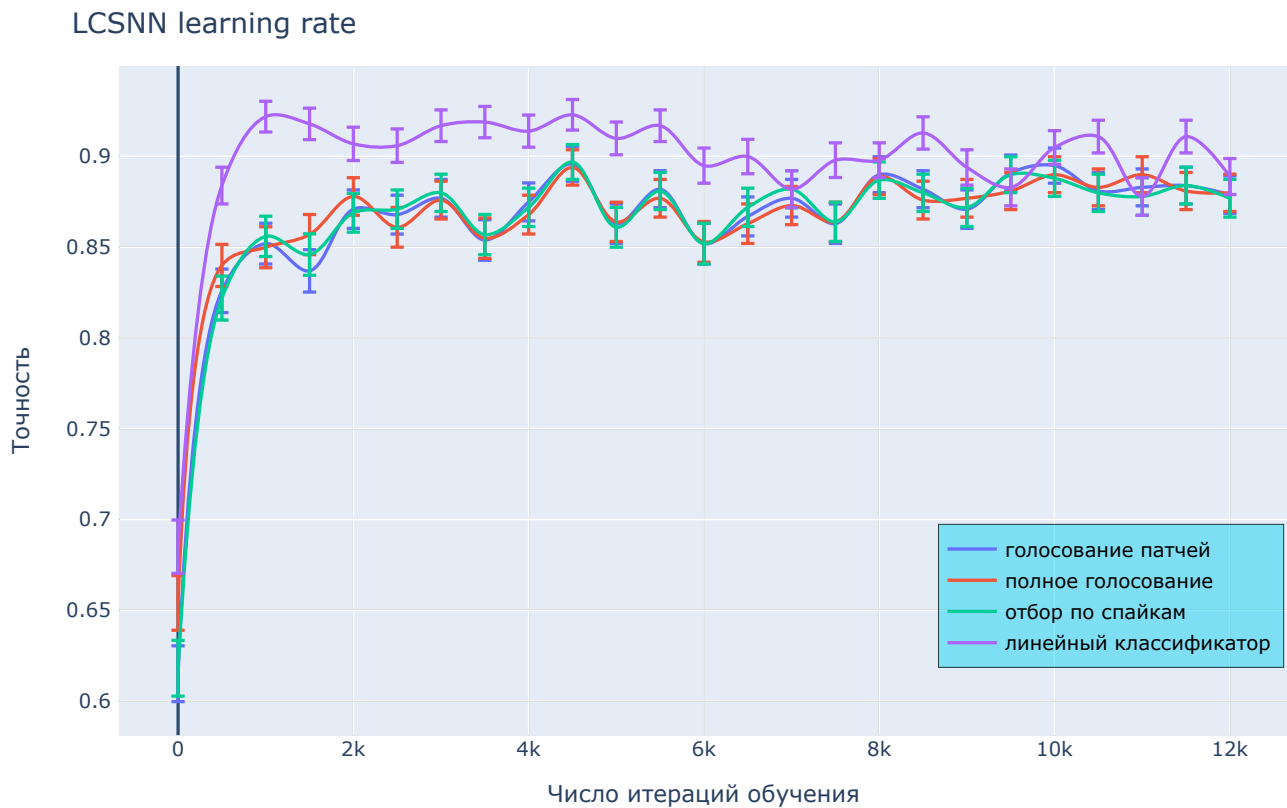


Рис. 4: Скорость обучения LCSNN

3.3 Сравнение эффективности операции свертки и локального рецептивного поля

Результаты экспериментов с различными архитектурами

Архитектура	Фильтры	Ядро	Веса	Нейроны	Точность	Погрешность
LCSNN	100	12	449100	900	0.8752	0.0090
LCSNN	100	8	798400	1600	0.8285	0.0021
LCSNN	25	12	95400	225	0.7939	0.0038
LCSNN	25	8	169600	400	0.7360	0.0103
CSNN	100	8	11350	1600	0.7736	0.0188
CSNN	25	12	3900	225	0.6577	0.0067
CSNN	25	8	1900	400	0.5807	0.0117
FCSNN	100	20	44950	100	0.7340	0.0866




Рис. 5: Веса XY слоя после обучения

3.4 Обучение связей конкуренции спайковой нейронной сети

3.5 Выводы

Выводы

4 Заключение

Было обнаружено, что обучение связей конкуренции нейронов, имеющих общие рецептивные поля, позволяет добиться большей точности распознавания изображений по сравнению с той же архитектурой, но с необучаемыми связями конкуренции. Также было показано, что LCSNN имеет преимущество над CSNN как по скорости обучения, так и по точности распознавания. Таким образом, локально соединенная сеть – перспективная нейросетевая архитектура, превосходящая классические алгоритмы в точности распознавания изображений при обучении без учителя, и подходит для реализации на вычислительном мемристормом нейрочипе.

5 Благодарности

Благодарности

Список литературы

- [1] Vyacheslav Demin и Dmitry Nekhaev. “Recurrent Spiking Neural Network Learning Based on a Competitive Maximization of Neuronal Activity”. в: *Frontiers in Neuroinformatics* 12 (нояб. 2018), с. 79. DOI: [10.3389/fninf.2018.00079](https://doi.org/10.3389/fninf.2018.00079).
- [2] Dmitry Nekhaev и Vyacheslav Demin. “Competitive Maximization of Neuronal Activity in Convolutional Recurrent Spiking Neural Networks”. в: янв. 2020, с. 255—262. ISBN: 978-3-030-30424-9. DOI: [10.1007/978-3-030-30425-6_30](https://doi.org/10.1007/978-3-030-30425-6_30).
- [3] Daniel J. Saunders и др. *Locally Connected Spiking Neural Networks for Unsupervised Feature Learning*. 2019. arXiv: [1904.06269](https://arxiv.org/abs/1904.06269) [cs.NE].
- [4] Li Wan и др. “Regularization of Neural Networks using DropConnect”. в: *Proceedings of the 30th International Conference on Machine Learning*. под ред. Sanjoy Dasgupta и David McAllester. т. 28. Proceedings of Machine Learning Research 3. Atlanta, Georgia, USA: PMLR, 17–19 Jun 2013, с. 1058—1066. URL: <http://proceedings.mlr.press/v28/wan13.html>.