

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА»

ФИЗИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА ОБЩЕЙ ФИЗИКИ И МОЛЕКУЛЯРНОЙ ЭЛЕКТРОНИКИ

БАКАЛАВРСКАЯ РАБОТА

**«МОДЕЛИРОВАНИЕ РАСПОЗНАВАНИЯ ОБРАЗОВ
НА ОСНОВЕ ИМПУЛЬСНЫХ НЕЙРОННЫХ СЕТЕЙ С
КОНКУРЕНЦИЕЙ ЛОКАЛЬНЫХ РЕЦЕПТИВНЫХ
ПОЛЕЙ»**

Выполнил студент:
406 группа
Гафни Д.

подпись студента

Научный руководитель:
Королёва А.В.

подпись научного руководителя

Научный консультант:
Дёмин В.А.

подпись научного консультанта

Допущена к защите
Зав.кафедрой _____

подпись зав.кафедрой

Москва

2020

Содержание

| | | |
|----------|---|-----------|
| 1 | Введение | 3 |
| 1.1 | Мотивация | 3 |
| 1.2 | Постановка задачи | 3 |
| 2 | Спайковые нейронные сети | 4 |
| 2.1 | Преимущества спайковых нейронных сетей | 4 |
| 2.2 | Модели нейронов спайковой нейронной сети | 4 |
| 2.2.1 | Пороговый нейрон | 5 |
| 2.2.2 | Пороговый интегратор | 6 |
| 2.2.3 | Пороговый интегратор с утечкой | 7 |
| 2.2.4 | Пороговый интегратор с утечкой и адаптивным порогом | 8 |
| 2.3 | Архитектуры спайковых нейронных сетей | 9 |
| 2.3.1 | Полносвязная сеть | 9 |
| 2.3.2 | Сверточная сеть | 9 |
| 2.3.3 | Локальное соединенная сеть | 10 |
| 2.4 | Алгоритмы обучения спайковых нейронных сетей | 11 |
| 2.4.1 | STDP | 12 |
| 2.4.2 | anti-STDP | 13 |
| 2.5 | Современные реализации спайковых нейронных сетей | 13 |
| 2.6 | Выводы | 13 |
| 3 | Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей | 14 |
| 3.1 | Описание задачи классификации | 14 |
| 3.2 | Особенности архитектуры | 14 |
| 3.3 | Обучение связей XU | 15 |
| 3.3.1 | Интерпретация активности спайковой нейронной сети | 16 |
| 3.4 | Сравнение эффективности операции свертки и локального рецептивного поля | 19 |
| 3.5 | Обучение связей UU (конкуренции) | 19 |
| 3.6 | Выводы | 22 |
| 4 | Заключение | 23 |
| 5 | Благодарности | 24 |

1 Введение

Импульсные (*спайковые*) нейронные сети (СНС) являются перспективным нейроморфным алгоритмом, биологически корректно моделируя взаимодействия нейронов мозга. Наибольший интерес СНС представляют для решения задач в реальном времени (принятие решений, распознавание образов), так как могут быть реализованы на специализированном вычислительно- и энергоэффективном нейрочипе (например, на основе мемристоров) [3] [7].

Стандартные методы обучения весов связей, применяющиеся в формальных нейронных сетях (метод обратного распространения ошибки) не представляется возможным применять к СНС из-за их дискретной и распределенной во времени природы. Таким образом, исследование алгоритмов обучения СНС представляется важной задачей.

1.1 Мотивация

Недостатки формальных нейронных сетей Современные формальные нейронные сети отлично справляются со многими задачами машинного обучения [8]. Однако их обучение - трудоемкий процесс, требующий больших вычислительных ресурсов. Обычно обучение ведется на десятках и сотнях тысячах примеров и может занимать месяцы. Как само обучение, так и последующее применение формальных нейросетевых алгоритмов далеки от эффективности. Это связано как с физически раздельным хранением значений весов и активаций нейронов, так и с самими вычислениями, которые носят тензорный характер. Современные процессоры не оптимизированы для подобных вычислений. Гораздо лучше процессоров для этих задач подходят GPU - архитектуры, изначально созданные для работы с компьютерной графикой, а потому лучше подходящие для тензорных вычислений, однако и они не дают желаемого результата. Число параметров в современных формальных нейронных сетях может достигать сотен миллионов [1].

1.2 Постановка задачи

В данной работе:

1. Изучается влияние обучения связей конкуренции [2] [5] между нейронами на точность распознавания образов в задаче классификации рукописных изображений цифр (MNIST) при обучении без учителя для архитектуры локально соединенной сети (Locally Connected Spiking Neural Network, LCSNN) [6]
2. Проводится сравнение этой архитектуры со сверточной сетью (Convolution Spiking Neural Network, CSNN) и полносвязной сетью (Fully Connected Spiking Neural Network, FCSNN).

2 Спайковые нейронные сети

Спайковая нейронная сеть - модель нейронной сети, элементами которой являются отдельные *нейроны* и *связи* между ними. Каждый нейрон имеет свой виртуальный *потенциал*, а каждая связь имеет некоторый *вес*. Нейроны обмениваются дискретными электрическими сигналами (*спайками*), имеющими очень короткую (≈ 1 мс) длительность. Входящий спайк носит название *пре-спайка*, а исходящий - *пост-спайка*. Влияние пре-спайков на потенциал нейрона определяется значением веса межнейронной связи. При накоплении потенциала, превышающего определенный *порог активации*, нейрон сам испускает пост-спайк, а после сбрасывает свое напряжение до некоторого *уровня релаксации*. При запуске сети активность некоторых входных нейронов задается определенным образом, после чего проводится симуляция на протяжении некоторого времени (≈ 250 мс), много большего длительности спайка.

2.1 Преимущества спайковых нейронных сетей

Спайковые нейронные сети имеют ряд преимуществ перед формальными нейронными сетями.

- Для обучения спайковых нейронных сетей могут применять локальные алгоритмы, которые используют для обновления веса каждой связи лишь информацию, источником которой являются нейроны, которые эта связь соединяет. Напротив, при обучении формальных нейронных сетей для обновления веса каждой связи используется информация о всех связях, стоящих между этой связью и выходом сети. Таким образом, сами по себе алгоритмы обучения спайковых нейронных сетей являются более эффективными, чем алгоритмы обучения формальных нейронных сетей.
- Более того, эти алгоритмы используют обучение без учителя (unsupervised learning), для которого не требуется ручной разметки данных.
- Спайковые нейронные сети могут быть реализованы на специализированном сверхэффективном нейроморфном процессоре. Такая реализация вместе с чисто алгоритмическим преимуществом спайковых нейронных сетей дает еще больший выигрыш в производительности и энергоэффективности [3] [7].
- Спайковые нейронные сети биологически корректно моделируют взаимодействия нейронов, что может использоваться для биологических симуляций нервной системы.

2.2 Модели нейронов спайковой нейронной сети

Реальный нейрон мозга является очень сложным объектом, поведение которого до сих пор не до конца изучено. Для спайковых нейронных сетей используются

упрощенные модели нейронов. Перечислим некоторые из них.

2.2.1 Пороговый нейрон

Это наиболее упрощенная модель нейрона. В каждый момент времени нейрон осуществляет следующие действия:

1. суммирует входящий сигнал

$$v(t) = v_{reset} + R \cdot \sum_{i=1}^n w_i I_i, \text{ где} \quad (1)$$

$v(t)$ - потенциал нейрона, v_{reset} - потенциал сброса, w_i - вес i -ой связи, I_i - «ток» i -ой связи, принимающий значение 1, если от нее есть спайк и 0, если его нет, а R - размерный коэффициент, численно равный 1.

2. осуществляет сравнение $v(t)$ с v_{thresh} - значением порога активации. Если потенциал превосходит порог активации, то нейрон испускает спайк и сбрасывает свой потенциал до значения v_{reset} , после чего наступает короткий *период рефрактерности*, при котором на протяжении времени $t_{refract}$ потенциал нейрона остается на уровне v_{reset} . Если потенциал не превосходит порог активации, то нейрон просто сбрасывает свой потенциал до значения v_{reset} .



Рис. 1: Типичная зависимость потенциала порогового нейрона от времени. Красными точками отмечены спайки нейрона.

2.2.2 Пороговый интегратор

Это немного усложненная модель нейрона (Integrate-and-Fire, IF), в которой нейрон приобретает способность накапливать входящие сигналы во времени. В каждый момент времени нейрон осуществляет следующие действия:

1. суммирует входящий сигнал

$$v(t) = v_{reset} + R \cdot \sum_{i=1}^n w_i I_i + R \cdot I(t), \text{ где} \quad (2)$$

$I(t)$ - накопленный к этому моменту ток от входящих спайков, а остальные переменные обозначены в 1

2. осуществляет сравнение $v(t)$ с v_{thresh} - значением порога активации. Если потенциал превосходит порог активации, то нейрон испускает спайк и сбрасывает свой потенциал до значения v_{reset} , а также сбрасывает $I(t)$ до 0, после чего наступает короткий период рефрактерности, при котором на протяжении времени $t_{refract}$ потенциал нейрона остается на уровне v_{reset} . Если же потенциал не превосходит порога активации, то нейрон просто обновляет значение $I(t)$.




Рис. 2: Типичная зависимость потенциала порогового интегратора от времени. Красными точками отмечены спайки нейрона.

2.2.3 Пороговый интегратор с утечкой

Это еще более усложненная модель нейрона, в которой его потенциал приобретает «утечку», то есть стремится с течением времени сравняться с *уровнем релаксации* v_{rest} . В этой модели динамика потенциала задается следующим уравнением:

$$\tau_v \frac{dv(t)}{dt} = -v(t) + v_{rest} + I(t) \cdot R, \text{ где} \quad (3)$$

где τ_v - временная константа симуляции, остальные переменные обозначены в 2 и 1.

После испускания каждого спайка наступает короткий период рефрактерности, при котором на протяжении времени $t_{refract}$ потенциал нейрона остается на уровне v_{reset} .

Таким образом, потенциал нейрона сам по себе стремится вернуться в состояние релаксации, так как если $I(t) = 0$ (нет входящих спайков) и $v(t) = v_{rest}$, то производная $\frac{dv(t)}{dt} = 0$, то есть потенциал нейрона будет оставаться постоянным на уровне v_{rest} .

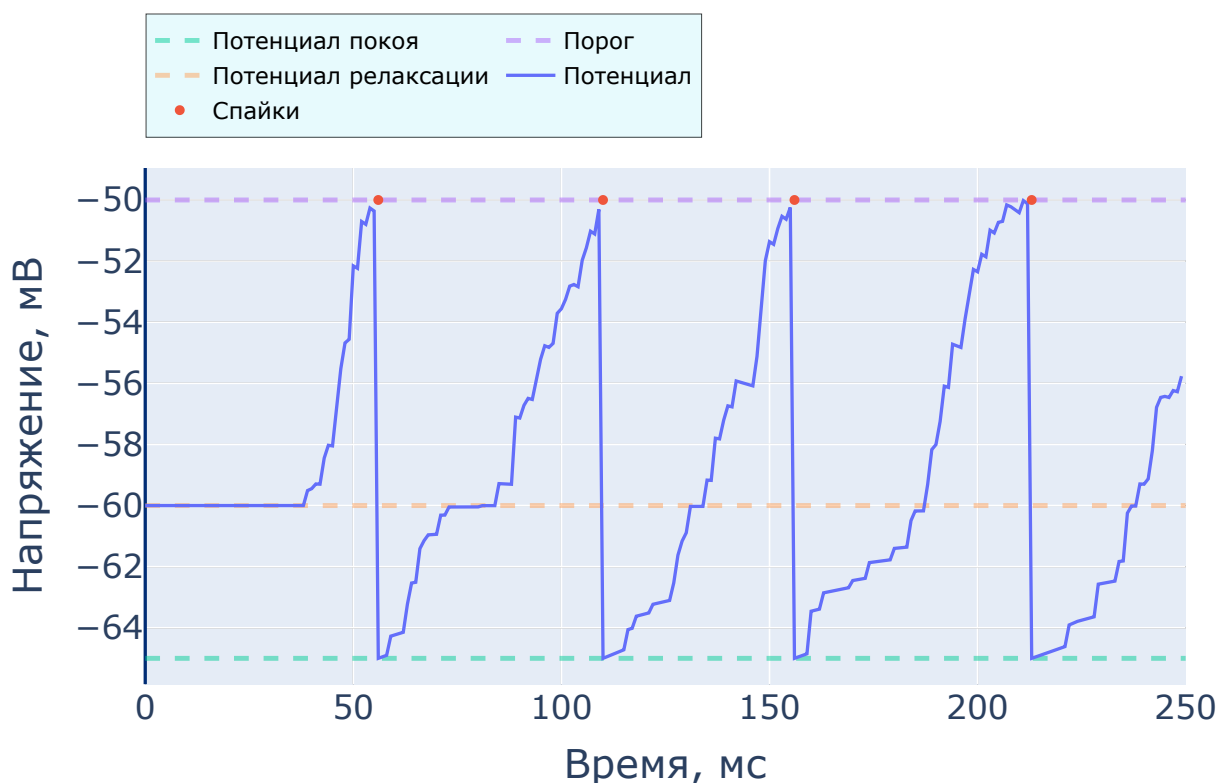


Рис. 3: Типичная зависимость потенциала порогового интегратора с утечкой от времени. Красными точками отмечены спайки нейрона.

2.2.4 Пороговый интегратор с утечкой и адаптивным порогом

В данной работе используется модель интегратора с утечкой и адаптивным порогом (Adaptive Leaky Integrate-and-Fire, A-LIF). В этой модели динамика потенциала задается следующим уравнением:

$$\tau_v \frac{dv(t)}{dt} = -v(t) + v_{rest} + I(t) \cdot R, \quad (4)$$

где $I(t)$ - ток, накопившийся в нейроне к моменту времени t , v_{rest} - уровень релаксации, τ_v - временная константа симуляции.

Таким образом, потенциал нейрона сам по себе стремится вернуться в состояние релаксации, так как если $I(t) = 0$ (нет входящих спайков) и $v(t) = v_{rest}$, то производная $\frac{dv(t)}{dt} = 0$, то есть потенциал нейрона будет оставаться постоянным на уровне v_{rest} .

Порог активации v_{thresh} у ALIF нейрона не является константой, а немного повышается при каждом спайке, релаксируя затем к своему начальному значению. Динамика порога активации задается следующими уравнениями:

$$v_{thresh} = \theta_0 + \theta(t), \quad (5)$$

где θ_0 - начальный порог активации, $\theta(t)$ - адаптивная добавка, которая вычисляется из условия

$$\tau_v \frac{d\theta(t)}{dt} = -\theta(t) \quad (6)$$

Таким образом, порог активации нейрона сам по себе стремится вернуться к начальному значению, так как при $\theta(t) = \theta_0$, то производная $\frac{d\theta(t)}{dt} = 0$, то есть порог активации нейрона будет оставаться постоянным на уровне θ_0 .

После испускания каждого спайка порог активации повышается на θ_{plus} , а также наступает короткий период рефрактерности, при котором на протяжении времени $t_{refract}$ потенциал нейрона остается на уровне v_{reset} .




Рис. 4: Типичная зависимость потенциала порогового интегратора с утечкой и адаптивным порогом от времени. Красными точками отмечены спайки нейрона.

Примечание: такой сильно адаптивный порог приведен лишь для иллюстрации.

2.3 Архитектуры спайковых нейронных сетей

Современные архитектуры формальных нейронных сетей могут переноситься на спайковые нейронные сети. При этом для увеличения эффективности разделения нейронов по признакам используются связи конкуренции (Рис. 14).

2.3.1 Полносвязная сеть

В полносвязной сети два слоя X и Y имеют связи между всеми парами нейронов.

Число нейронов Y слоя и его структура задается произвольно. Число параметров (весов) такой сети равно $\frac{XY}{2}$.

2.3.2 Сверточная сеть

В сверточной сети для построения связей и формирования Y слоя применяется операция *свертки*. Пусть есть X слой нейронов $N \times M$. Операция свертки

определяется 4 параметрами - размером *ядра* свертки (k_1, k_2) и *шагом* свертки (s_1, s_2) .

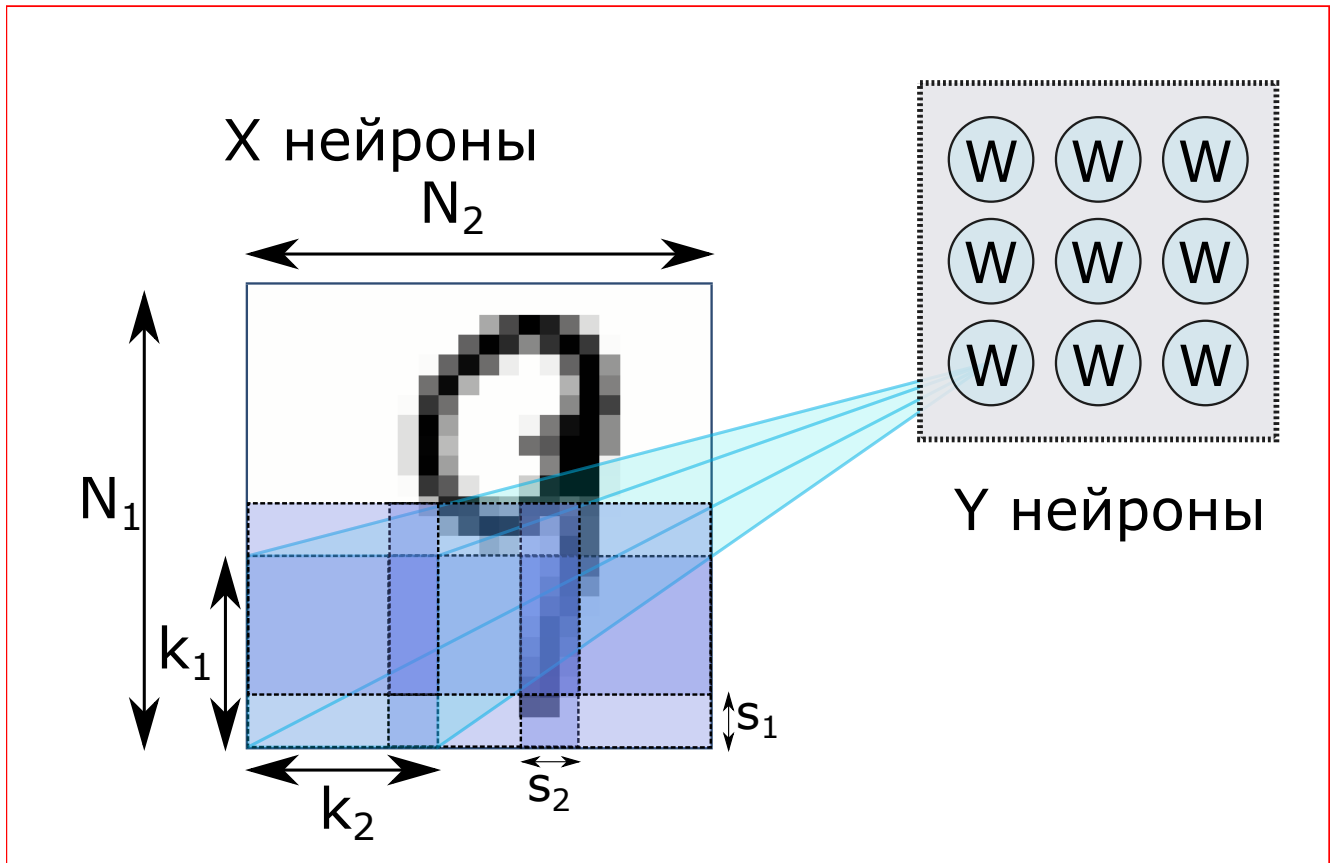


Рис. 5: Свертка

Y нейроны также называются *сверточным* слоем. Все они имеют общие (численно совпадающие) веса W размерности $(k_1 \times k_2)$. Отличаются они положением области X слоя, с которой имеют связи.

Размерность Y слоя равна $(\frac{N_1 - k_1 - 2}{s_1}, \frac{N_2 - k_2 - 2}{s_2})$. Число параметров свертки равно $k_1 \cdot k_2$.

Заметим, что свертки могут применяться над предыдущим слоем любой размерности. Здесь была описана 2-D свертка, принцип ее работы аналогично переносится и на N-D.

В дальнейшем ядро свертки $k_1 \times k_2$ будем также называть синонимами - «*область видимости*», «*рецептивное поле*». Также в этой работе для упрощения подбора оптимальных параметров используются только квадратные свертки, т.е. $k_1 = k_2 \equiv k$, а $s_1 = s_2 \equiv s$. Все сети в этой работе имеют шаг $s = 2$.

2.3.3 Локально соединенная сеть

Локально соединенная архитектура совпадает со сверточной с тем единственным отличием, что веса Y нейронов для нее не являются общими, то есть каждый Y нейрон имеет свои уникальные веса.




Рис. 6: Локальное соединение

Размерность Y слоя для локально соединенной сети равна $(\frac{N_1-k_1-2}{s_1}, \frac{N_2-k_2-2}{s_2})$, число связей равно $\frac{N_1-k_1-2}{s_1} \cdot \frac{N_2-k_2-2}{s_2} \cdot k_1 \cdot k_2$.

Как и свертка, локально соединенный слой может быть аналогичным образом основан на слое любой размерности. Для локально соединенных сетей также используются только квадратные свертки, т.е. $k_1 = k_2 \equiv k$, а $s_1 = s_2 \equiv s$. Все сети в этой работе имеют шаг $s = 2$.

2.4 Алгоритмы обучения спайковых нейронных сетей

Процесс нахождения оптимальных значений весов связей сети называется обучением. Обучением может вестись как с учителем - если алгоритму обучения используется информация об истинных значениях, предсказываемых сетью - так и без учителя. Преимущество первого класса алгоритмов обучения заключается в как правило лучших результатах, а недостаток - в необходимости предварительной разметки обучающей выборки человеком, что не всегда представляется возможным. В свою очередь, обучения без учителя может давать немного худшие результаты в зависимости от задачи, однако не требует разметки данных, что часто позволяет подготавливать большие объемы обучающей выборки, чем при обучении без учителя. В данной работе для обучения используется правило STDP (Spike Timing Dependent Plasticity).

2.4.1 STDP

STDP - биологически инспирированное правило обучения без учителя. При получении пре-спайка и испускании пост-спайка вес w связи, по которой пришел пре-спайк, увеличивается на Δw , где

$$\Delta w = \begin{cases} A_+ \cdot e^{-\frac{t_{pre}-t_{post}}{\tau_+}}, & t_{pre} - t_{post} > 0 \\ A_- \cdot e^{-\frac{t_{pre}-t_{post}}{\tau_-}}, & t_{pre} - t_{post} < 0 \end{cases} \quad (7)$$

Заметим, что

$$\begin{cases} A_+ > 0 \\ A_- < 0 \end{cases}$$




Рис. 7: Правило STDP. График зависимости изменения веса от разности времени регистрации пост- и пре-спайков.

Таким образом, в процессе обучения у каждого нейрона увеличивается вес связей, по которым систематически пре-спайк приходит перед излучением пост-спайка, и наоборот уменьшается у тех связей, для которых такой закономерности не наблюдается. После такого обучения нейрон начинает активнее реагировать на пре-спайки от нейронов, соединенных с ним связями с большим весом, а значит, начинает сам испускать пост-спайк, если в короткий промежуток времени эти нейроны будут активны одновременно. Этим он объединяет их активность, посылая пост-спайк дальше по сети.

2.4.2 anti-STDP

anti-STDP является правилом обучения, обратным к STDP.

$$\Delta w = \begin{cases} A_+ \cdot e^{-\frac{t_{pre}-t_{post}}{\tau_+}}, & t_{pre} - t_{post} > 0 \\ A_- \cdot e^{-\frac{t_{pre}-t_{post}}{\tau_-}}, & t_{pre} - t_{post} < 0 \end{cases} \quad (8)$$
$$\begin{cases} A_+ < 0 \\ A_- > 0 \end{cases}$$




Рис. 8: Правило anti-STDP. График зависимости изменения веса от разности времени регистрации пост- и пре- спайков.

Таким образом, в процессе обучения связей между нейронами, активность которых коррелирует, уменьшаются. Это правило используется для обучения связей конкуренции.

2.5 Современные реализации спайковых нейронных сетей

Современные реализации

2.6 Выводы

3 Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей

3.1 Описание задачи классификации

Для работы была выбрана классическая задача машинного обучения - задача классификации изображений рукописных цифр из набора данных MNIST. MNIST состоит из размеченных обучающей и тестовых выборок объемами 60000 и 10000 изображений. Изображения имеют размер 28×28 пикселя и являются черно-белыми. Из-за необходимости калибровки сетей (3.3.1) обучающая выборка была разбита на 50000 изображений для обучения (обучающая выборка) и 10000 изображений для калибровки (калибровочная выборка).



Рис. 9: Изображения MNIST

В этой работе изображения обрезаются так, что используется только центральная область 20×20 пикселей.

3.2 Особенности архитектуры

Нейросетевая архитектура LCSNN [6] вдохновлена строением зрительной коры мозга. Y слой сети состоит из n каналов, каждый из которых является локально соединенным с X слоем нейронов.


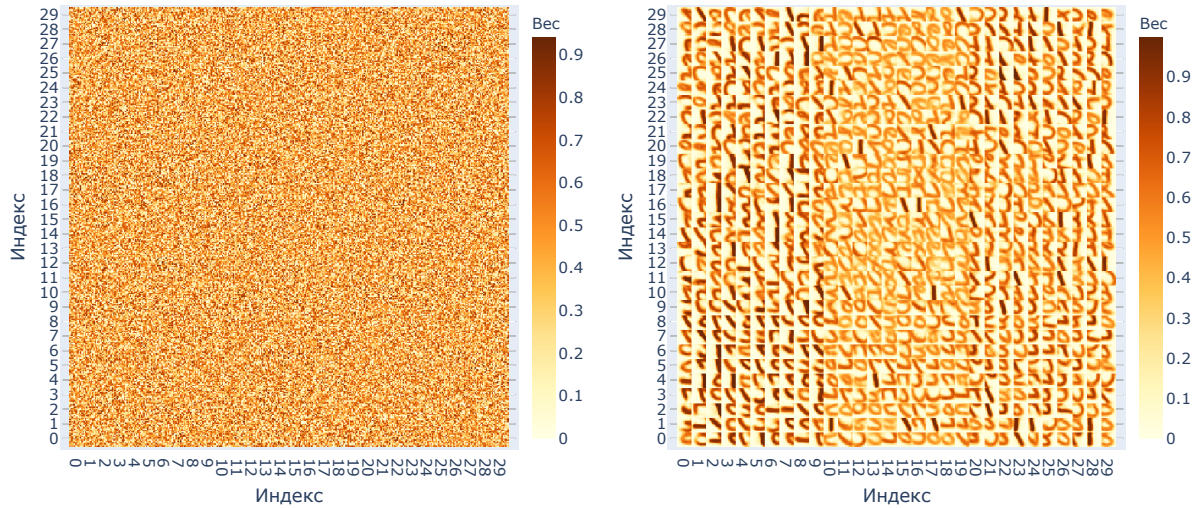


Рис. 10: Схема архитектуры LCSNN

Нейроны, имеющие общие рецептивные поля соединяются связями конкуренции. Такие связи имеют отрицательные веса, а значит, негативно влияют на активность. Нейроны, не имеющие общего рецептивного поля (а значит, реагирующие на разные области изображения) не конкурируют между собой.

3.3 Обучение связей ХУ

Для уменьшения размера моделей изображения обрезаются до размера 20×20 пикселей. Края изображений часто практически пусты, поэтому это практически не влияет на объем информации, доступный сети. Для каждого изображения при помощи распределения Пуассона с математическим ожиданием, пропорциональным интенсивности соответствующего пикселя генерируются X спайки. Обучение связей $ХУ$ производится по правилу STDP [4]. После каждой итерации обучения производится нормализация весов - веса каждого нейрона умножаются на такое число, чтобы их сумма стала равной определенной константе. Это делается для избежания возникновения слишком больших отдельных весов. Значение константы нормализации есть важный гиперпараметр модели, который подбирается для каждой конкретной архитектуры.



(a) Веса перед обучением

(b) Веса после обучения

Рис. 11: Визуализация весов XU связей. Каждый квадратик 12×12 соответствует весам одного U нейрона.


3.3.1 Интерпретация активности спайковой нейронной сети

Для интерпретации активности нейронов U слоя сети использовалось несколько методов.

- Голосование патчей
- Общее голосование нейронов
- Голосование нейронов с предварительным отбором по спайкам
- Линейный классификатор

Преимущество первых трех методов заключается в их простоте. Они могут быть реализованы на аппаратном уровне. Однако, линейный классификатор значительно превосходит их по точности.

Калибровка голосов Для первых трех методов необходимо произвести калибровку голосов нейронов. Каждому нейрону U слоя ставится в соответствие 10 чисел (голосов) для каждого возможного класса цифр (от 0 до 9). Голос вычисляется как среднее число спайков данного нейрона в ответ на демонстрацию сети данной цифры. Для всех сетей использовалась калибровка на 10000 примерах из калибровочной выборки. Заметим, что калибровка не является частью обучения сети, так как она входит лишь в алгоритм интерпретации поведения сети. Эти голоса используются как мера уверенности нейрона в каждом из классов. После демонстрации изображения сети подсчитывается общее количество спайков для каждого нейрона U слоя.



(a) Голоса нейронов Y слоя.



(b) Среднее значение голоса для топ- n класса, где топ-1 - класс с максимальным голосом нейрона, топ-10 - класс с минимальным голосом нейрона.

Рис. 12: Визуализация голосов нейронов Y слоя. Высокие значения соответствуют большой специализации нейрона на соответствующем классе.

Далее результатом будем называть произведение количества спайков нейрона на голос.

Общее голосование Ответом сети считается класс с максимальным результатом среди всех нейронов.

Голосование патчей Для каждого рецептивного поля ищется нейрон с максимальным результатом. Ответом сети считается класс с максимальным результатом среди этих нейронов.

Отбор по спайкам Для каждого рецептивного поля ищется нейрон с максимальным количеством спайков. Ответом сети считается класс с максимальным результатом среди этих нейронов.

Линейный классификатор Суммы спайков нейронов Y слоя используются для обучения линейного классификатора. Для обучения классификатора также используется калибровочная выборка.

Оценка алгоритма интерпретации Для оценки работы алгоритма интерпретации используется точность - отношение количества верно распознанных цифр к размеру тестовой выборки. В этой работе во всех случаях размер тестовой выборки составляет 10000.

Сравнение алгоритмов интерпретации активности сети LCSNN отличаются большой скоростью обучения. Были построены кривые обучения для различных алгоритмов интерпретации активности сети. Точность измерялась через каждые 250 итераций обучения. Для калибровки алгоритма интерпретации использовалась калибровочная выборка объемом 5000. Для измерения точности использовалась тестовая выборка объемом 1000.

Видно, что через несколько тысяч итераций обучения точность распознавания выходит на плато насыщения, после чего уже не возрастает. Видно, что три метода голосования в целом не отличаются по точности, а линейный классификатор значительно превосходит их все. Заметим, что точность даже необученной сети может достигать 70% за счет калибровки механизма интерпретации.




Рис. 13: Скорость обучения LCSNN. Сравнение различных алгоритмов интерпретации активности.

3.4 Сравнение эффективности операции свертки и локального рецептивного поля

Были проведены эксперименты по измерению точности сетей с различными архитектурами. Из-за очень высоких вычислительных нагрузок не ставилось задачи по нахождению параметров, идеально обеспечивающих максимальную точность для каждой архитектуры. Эти параметры были подобраны приблизительно, поэтому могли не попасть в максимум точности, однако величина расхождения не превышает 1-2%. Все точности посчитаны при помощи алгоритма интерпретации активности на основе голосования нейронов (учитывался лучший результат). Заметим, что при использовании линейного классификатора в качестве алгоритма интерпретации удалось достигнуть 95% точности для локально соединенной сети из 1000 каналов с размером ядра 12.

Таблица 1: Результаты сравнения различных архитектур спайковых нейронных сетей. Для каждой сети точность измерялась $N = 5$ раз. В таблице указаны средние значения и стандартное отклонение для точности.

| Архитектура | Каналы | Ядро | Веса | Нейроны | Точность, % |
|--------------------|--------|------|--------|---------|----------------|
| LCSNN | 100 | 12 | 449100 | 900 | 87.5 ± 0.9 |
| LCSNN | 100 | 8 | 798400 | 1600 | 82.9 ± 0.2 |
| LCSNN ¹ | 25 | 12 | 95400 | 225 | 82.3 ± 1.0 |
| LCSNN | 25 | 12 | 95400 | 225 | 80.1 ± 1.0 |
| LCSNN | 25 | 8 | 169600 | 400 | 73.6 ± 1.0 |
| CSNN | 81 | 12 | 543105 | 729 | 76.2 ± 1.7 |
| CSNN | 100 | 8 | 11350 | 1600 | 77.4 ± 1.9 |
| CSNN | 25 | 12 | 3900 | 225 | 65.8 ± 0.7 |
| CSNN | 25 | 8 | 1900 | 400 | 58.1 ± 1.2 |
| FCSNN | 100 | 20 | 44950 | 100 | 73.4 ± 0.9 |

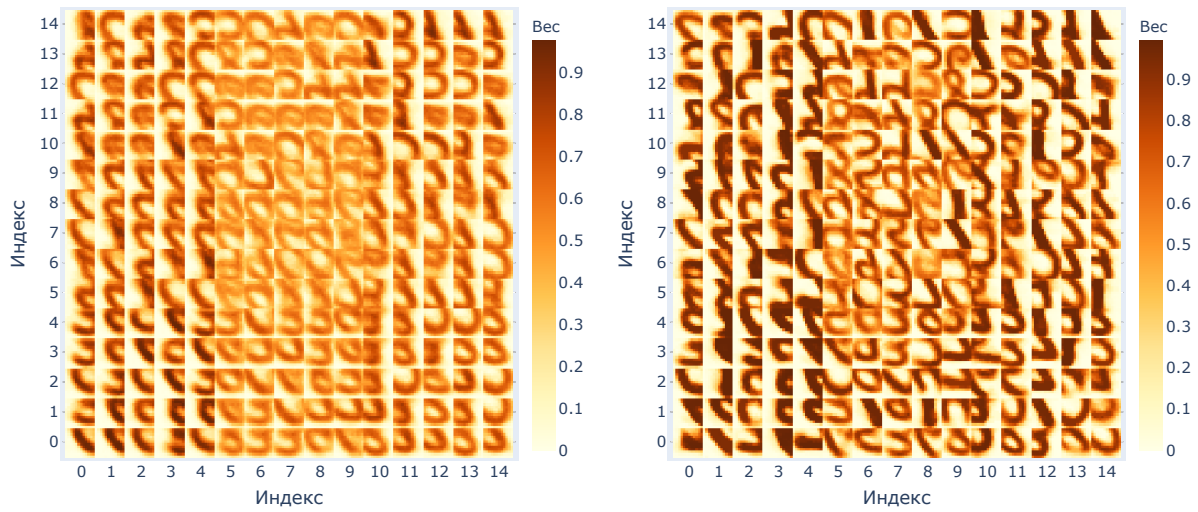
Видно, что локально соединенная сеть превосходит сверточную сеть по точности даже при чуть превышающем числе параметров последней. Также видно, что не следует использовать слишком маленький размер ядра свертки. Это приводит к выучиванию сетью менее значительных признаков. Заметим, что в классическом машинном обучении используются либо неглубокие сети с большими ядрами свертки, либо глубокие сети с маленькими ядрами свертки.

3.5 Обучение связей YU (конкуренции)

Связи YU очень сильно влияют на обучение связей XU . Большие по модулю значения способствуют вариативности в обучении Y нейронов, так для каждого рецептивного поля одновременно активными не могут быть нейроны, имеющие

¹Сеть с обучением связей конкуренции

схожие веса XU , а малые по модулю значения не позволяют нейронам специализироваться.



(а) Слабо специализированные веса, вес конкуренции равен -10

(б) Специализированные веса, вес конкуренции равен -100

Рис. 14: Влияние конкуренции на обучение XU связей


Все сети до этого момента имели фиксированные веса конкуренции. Было обнаружено, что обучение весов конкуренции позволяет повысить точность сети. Для обучения связей YU используется правило anti-STP (разд. 2.4.2). При помощи варьирования параметров этого правила были получены различные распределения весов конкуренции.




Рис. 15: Различные распределения весов конкуренции

Видно, что точность сети повышается при тяготении распределения весов конкуренции в сторону больших по модулю значений. Заметим, что целью являлось не нахождение параметров сети, обеспечивающих максимальную точность, а исследования влияния обучения или не-обучения конкуренции на точность сети с данной конфигурацией остальных параметров.


Примечательно, что не все связи YU получают большие по модулю значения. Это объясняется тем, что нейроны, специализирующиеся на значительно разных признаках, не нуждаются в конкуренции, так как они не проявляют высокую активность одновременно.




(a) Очень слабая конкуренция



(b) Слабая конкуренция



(c) Средняя конкуренция



(d) Сильная конкуренция

Рис. 16: Визуализация весов конкуренции поверх весов XU . Примеры соответствуют сетям из Рис. 15. Изображены только веса конкуренции для одного нейрона в каждом рецептивном поле для избегания загромождения визуализации. Насыщенный синий цвет соответствует большей по модулю конкуренции (используется среднее арифметическое между весов W_{ij} и W_{ji}). Видно, что похожие признаки сильнее конкурируют между собой, чем различные.

3.6 Выводы

В результате проведения работы было проведено сравнение локально соединенной спайковой нейронной сети со сверточной спайковой нейронной сетью. Показано, что локально соединенная архитектура значительно превосходит сверточную по точности при одинаковом числе параметров.

Также было обнаружено, что обучение конкуренции позволяет дополнительно повысить точность сети.

4 Заключение

Локально соединенная сеть – перспективная нейросетевая архитектура, подходящая для реализации на вычислительном нейрочипе. Способность быстро выходить на плато кривой обучения позволяет использовать локально соединенные сети для обучения на выборка сравнительно небольшого объема (3000-5000). Использование дополнительного алгоритма интерпретации активности, такого как линейный классификатор, позволяет повысить эффективность сети.

Число параметров (весов) сети определяет энергоэффективность мемристорного нейрочипа, так как каждый вес обычно представлен физическим элементом. Таким образом, это главный фактор, определяющий эффективность любой модели. Было показано, что локально соединенная сеть превосходит сверточную в точности при примерно одинаковом числе параметров.

Также было показано, что при помощи обучения связей конкуренции можно добиться большей точности, чем при фиксированных весах конкуренции.

В качестве перспектив для исследования можно отметить более глубокое изучение обучения конкуренции, а именно анализ распределений весов конкуренции, а также подбор оптимальных параметров обучения конкуренции.

Все материалы этой работы находятся в репозитории
<https://github.com/danielgafni/bachelor>

5 Благодарности

Приношу свои благодарности Дёмину Вячеславу Александровичу, Нехаеву Дмитрию Вадимовичу и Королеву Александру Валерьевну за помощь в проведении научной работы.

Список литературы

- [1] Md. Zahangir Alom и др. “A State-of-the-Art Survey on Deep Learning Theory and Architectures”. в: *Electronics* 8 (март 2019), с. 292. DOI: [10.3390/electronics803](https://doi.org/10.3390/electronics803)
- [2] Vyacheslav Demin и Dmitry Nekhaev. “Recurrent Spiking Neural Network Learning Based on a Competitive Maximization of Neuronal Activity”. в: *Frontiers in Neuroinformatics* 12 (нояб. 2018), с. 79. DOI: [10.3389/fninf.2018.00079](https://doi.org/10.3389/fninf.2018.00079).
- [3] De Ma и др. “Darwin: A neuromorphic hardware co-processor based on spiking neural networks”. в: *Journal of Systems Architecture* 77 (2017), с. 43—51. ISSN: 1383-7621. DOI: <https://doi.org/10.1016/j.sysarc.2017.01.003>. URL: <http://www.sciencedirect.com/science/article/pii/S1383762117300231>.
- [4] Henry Markram, Wulfram Gerstner и Per Jesper Sjöström. “A History of Spike-Timing-Dependent Plasticity”. в: *Frontiers in Synaptic Neuroscience* 3 (2011), с. 4. ISSN: 1663-3563. DOI: [10.3389/fnsyn.2011.00004](https://doi.org/10.3389/fnsyn.2011.00004). URL: <https://www.frontiersin.org/article/10.3389/fnsyn.2011.00004>.
- [5] Dmitry Nekhaev и Vyacheslav Demin. “Competitive Maximization of Neuronal Activity in Convolutional Recurrent Spiking Neural Networks”. в: ЯНВ. 2020, с. 255—262. ISBN: 978-3-030-30424-9. DOI: [10.1007/978-3-030-30425-6_30](https://doi.org/10.1007/978-3-030-30425-6_30).
- [6] Daniel J. Saunders и др. *Locally Connected Spiking Neural Networks for Unsupervised Feature Learning*. 2019. arXiv: [1904.06269](https://arxiv.org/abs/1904.06269) [cs.NE].
- [7] Guangzhi Tang, Arpit Shah и Konstantinos P. Michmizos. *Spiking Neural Network on Neuromorphic Hardware for Energy-Efficient Unidimensional SLAM*. 2019. arXiv: [1903.02504](https://arxiv.org/abs/1903.02504) [cs.R0].
- [8] Li Wan и др. “Regularization of Neural Networks using DropConnect”. в: *Proceedings of the 30th International Conference on Machine Learning*. под ред. Sanjoy Dasgupta и David McAllester. т. 28. Proceedings of Machine Learning Research 3. Atlanta, Georgia, USA: PMLR, 17–19 Jun 2013, с. 1058—1066. URL: <http://proceedings.mlr.press/v28/wan13.html>.