

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ  
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ  
имени М.В.ЛОМОНОСОВА»

ФИЗИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА ОБЩЕЙ ФИЗИКИ И МОЛЕКУЛЯРНОЙ ЭЛЕКТРОНИКИ

**«МОДЕЛИРОВАНИЕ РАСПОЗНАВАНИЯ ОБРАЗОВ НА  
ОСНОВЕ ИМПУЛЬСНЫХ НЕЙРОННЫХ СЕТЕЙ С  
КОНКУРЕНЦИЕЙ ЛОКАЛЬНЫХ РЕЦЕПТИВНЫХ ПОЛЕЙ»**

Выполнил студент:  
406 группа  
Гафни Д.

---

подпись студента

Научный руководитель:  
Королёва А.В.

---

подпись научного руководителя

Научный консультант:  
Дёмин В.А.

---

подпись научного консультанта

Москва  
2020

# Содержание

<b>1</b>	<b>Описание проблемы</b>	<b>2</b>
<b>2</b>	<b>Постановка задачи</b>	<b>2</b>
<b>3</b>	<b>Спайковые нейронные сети</b>	<b>3</b>
<b>4</b>	<b>Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей</b>	<b>3</b>
4.1	Описание задачи классификации . . . . .	3
4.2	Особенности архитектуры . . . . .	3
4.3	Обучение связей $XU$ . . . . .	4
4.3.1	Интерпретация активности спайковой нейронной сети . . . . .	4
4.4	Сравнение эффективности операции свертки и локального рецептивного поля	5
4.5	Обучение связей $YU$ (конкуренции) . . . . .	6
<b>5</b>	<b>Выводы</b>	<b>6</b>

## 1 Описание проблемы

Импульсные (спайковые) нейронные сети (СНС) являются перспективным нейроморфным алгоритмом, биологически корректно моделируя взаимодействия нейронов мозга. Наибольший интерес СНС представляют для решения задач в реальном времени (принятие решений, распознавание образов), так как могут быть реализованы на специализированном вычислительно- и энергоэффективном мемристорном нейрочипе, так как

Стандартные методы обучения весов связей, применяющиеся в формальных нейронных сетях (метод обратного распространения ошибки) не представляется возможным применять к СНС из-за их дискретной и распределенной во времени природы. Таким образом, исследование алгоритмов обучения СНС представляется важной задачей.

Современные формальные нейронные сети отлично справляются со многими задачами машинного обучения [5]. Однако их обучение - трудоемкий процесс, требующий больших вычислительных ресурсов. Обычно обучение ведется на десятках и сотнях тысячах примеров и может занимать месяцы. Как само обучение, так и последующее применение формальных нейросетевых алгоритмов далеки от эффективности. Это связано как с физически раздельным хранением значений весов и активаций нейронов, так и с самими вычислениями, которые носят тензорный характер. Современные процессоры не оптимизированы для подобных вычислений. Гораздо лучше процессоров для этих задач подходят GPU - архитектуры, изначально созданные для работы с компьютерной графикой и больше оптимизированные для тензорных вычислений, однако и они не дают желаемого результата. Число параметров в современных формальных нейронных сетях может достигать сотен миллионов [1].

## 2 Постановка задачи

В данной работе:

1. Изучается влияние обучения связей конкуренции [2] [3] между нейронами на точность распознавания образов в задаче классификации рукописных изображений цифр (MNIST) при обучении без учителя для архитектуры локально соединенной сети (Locally Connected Spiking Neural Network, LCSNN) [4]
2. Проводится сравнение этой архитектуры со сверточной сетью (Convolution Spiking Neural Network, CSNN) и полносвязной сетью (Fully Connected Spiking Neural Network, FCSNN).

### 3 Спайковые нейронные сети

Спайковая нейронная сеть - модель нейронной сети, элементами которой являются отдельные нейроны и связи между ними. Каждый нейрон имеет свой виртуальный потенциал, а каждая связь имеет некоторый вес. Нейроны обмениваются дискретными электрическими сигналами (спайками), имеющими очень короткую ( $\approx 1$  мс) длительность. Входящий спайк носит название пре-спайка, а исходящий - пост-спайка. Влияние пре-спайков на потенциал нейрона определяется значением веса межнейронной связи. При накоплении потенциала, превышающего определенный порог активации, нейрон сам испускает пост-спайк, а после сбрасывает свое напряжение до некоторого уровня релаксации. При запуске сети активность некоторых входных нейронов задается определенным образом, после чего проводится симуляция на протяжении некоторого времени ( $\approx 250$  мс), много большего длительности спайка.

## 4 Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей

### 4.1 Описание задачи классификации

Для работы была выбрана классическая задача машинного обучения - задача классификации изображений рукописных цифр из набора данных MNIST. MNIST состоит из размеченных обучающей и тестовых выборок объемами 60000 и 10000 изображений. Изображения имеют размер 28x28 пикселей и являются черно-белыми. Из-за необходимости калибровки сетей (4.3.1) обучающая выборка была разбита на 50000 изображений для обучения (обучающая выборка) и 10000 изображений для калибровки (калибровочная выборка).

В этой работе изображения обрезаются так, что используется только центральная область 20x20 пикселей.





Рис. 1: Изображения MNIST

### 4.2 Особенности архитектуры

Эта нейросетевая архитектура вдохновлена строением зрительной коры мозга. В отличие от сверточной сети, ее нейроны не имеют общих весов, которые потому и называются локальными.



Нейроны, имеющие общие рецептивные поля, соединяются связями конкуренции. Такие связи имеют отрицательные веса, а значит, негативно влияют на активность нейрона. Заме-

тим, что нейроны, не имеющие общего рецептивного поля (а значит, реагирующие на разные области изображения) не конкурируют между собой.

## 4.3 Обучение связей $XU$

Параметры обучения


### 4.3.1 Интерпретация активности спайковой нейронной сети

Для интерпретации активности нейронов  $Y$  слоя сети использовалось несколько методов.


**Калибровка голосов** Для первых трех методов необходимо произвести калибровку голосов нейронов. Каждому нейрону  $Y$  слоя ставится в соответствие 10 чисел (голосов) для каждого возможного класса цифр (от 0 до 9). Голос вычисляется как среднее число спайков данного нейрона в ответ на демонстрацию сети данной цифры. Для всех сетей использовалась калибровка на 10000 примерах из калибровочной выборки. Заметим, что калибровка не является частью обучения сети, так как она входит лишь в алгоритм интерпретации поведения сети. Эти голоса используются как мера уверенности нейрона в каждом из классов. После демонстрации изображения сети подсчитывается общее количество спайков для каждого нейрона  $Y$  слоя.

Далее результатом будем называть произведение количества спайков нейрона на голос.

**Голосование патчей** Для каждого рецептивного поля ищется нейрон с максимальным результатом. Ответом сети считается класс с максимальным результатом среди этих нейронов.




(a) Веса перед обучением




(b) Веса после обучения

Рис. 2: Визуализация весов  $XU$  связей. Каждый квадратик соответствует весам одного  $Y$  нейрона.



(a) Голоса нейронов  $Y$  слоя.



(b) Среднее значение голоса для топ- $n$  класса, где топ-1 - класс с максимальным голосом нейрона, топ-10 - класс с минимальным голосом нейрона.

Рис. 3: Визуализация голосов нейронов  $Y$  слоя. Высокие значения соответствуют большой специализации нейрона на соответствующем классе.

#### 4.4 Сравнение эффективности операции свертки и локального рецептивного поля

Были проведены эксперименты по измерению точности сетки с различными архитектурами. Из-за очень высоких вычислительных нагрузок не ставилось задачи по нахождению параметров, идеально обеспечивающих максимальную точность для каждой архитектуры. Эти параметры были подобраны приблизительно, поэтому могли не попасть в максимум точности, однако величина расхождения не превышает 1-2%.

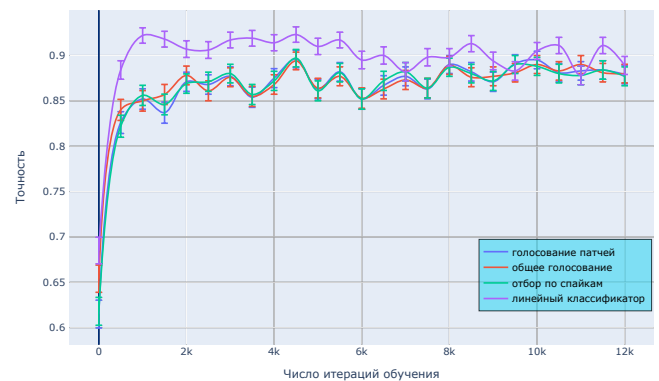


Рис. 4: LCSNN отличаются большой скоростью обучения. Через несколько тысяч итераций точность распознавания выходит на плато насыщения, после чего уже не возрастает. Видно, что три метода голосования в целом не отличаются по точности, а линейный классификатор значительно превосходит их все.

Архитектура	Фильтры	Ядро	Веса	Нейроны	Точность	Погрешность
LCSNN	100	12	449100	900	0.8752	0.0090
LCSNN	100	8	798400	1600	0.8285	0.0021
LCSNN	25	12	95400	225	0.8005	0.0102
LCSNN	25	8	169600	400	0.7360	0.0103
CSNN	100	8	11350	1600	0.7736	0.0188
CSNN	25	12	3900	225	0.6577	0.0067
CSNN	25	8	1900	400	0.5807	0.0117
FCSNN	100	20	44950	100	0.7340	0.0866

Видно, что локально соединенная сеть превосходит сверточную сеть по точности при одинаковом числе нейронов (в таблице указано количество нейронов  $Y$  слоя).

## 4.5 Обучение связей $YU$ (конкуренции)

Связи  $YU$  очень сильно влияют на обучение связей  $XU$ . Большие по модулю значения способствуют вариативности в обучении  $Y$  нейронов, так для каждого рецептивного поля одновременно активными не могут быть нейроны, имеющие схожие веса  $XU$ , а малые по модулю значения не позволяют нейронам специализироваться.


Все сети до этого момента имели фиксированные веса конкуренции. Было обнаружено, что обучение весов конкуренции позволяет повысить точность сети. При помощи варьирования параметров STDP были получены различные распределения весов конкуренции.

Видно, что точность сети повышается при тяготении распределения весов конкуренции в сторону больших по модулю значений. Заметим, что целью являлось не нахождение параметров сети, обеспечивающих максимальную точность, а исследования влияния обучения или не-обучения конкуренции на точность сети с данной конфигурацией остальных параметров.

Примечательно, что не все связи  $YU$  получают большие по модулю значения. Это объясняется тем, что нейроны, специализирующиеся на значительно разных элементах, не нуждаются в конкуренции, так как они не проявляют высокую активность одновременно.

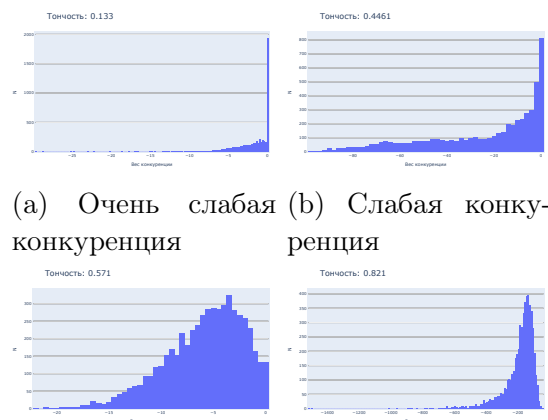
## 5 Выводы

Было обнаружено, что обучение связей конкуренции нейронов, имеющих общие рецептивные поля, позволяет добиться большей точности распознавания изображений по сравнению с той же архитектурой, но с необучаемыми связями конкуренции. Также было показано, что LCSNN имеет



(а) Слабо специализированные веса, вес конкуренции равен  $-10$  (б) Специализированные веса, вес конкуренции равен  $-100$

Рис. 5: Влияние конкуренции на обучение  $XU$  связей



(а) Очень слабая конкуренция (б) Слабая конкуренция

(с) Средняя конкуренция (д) Сильная конкуренция

Рис. 6: Различные распределения весов конкуренции

преимущество над CSNN как по скорости обучения, так и по точности распознавания. Таким образом, локально соединенная сеть – перспективная нейросетевая архитектура, превосходящая классические алгоритмы в точности распознавания изображений при обучении без учителя, и подходит для реализации на вычислительном мемристормом нейрочипе.

## Список литературы

- [1] Md. Zahangir Alom и др. “A State-of-the-Art Survey on Deep Learning Theory and Architectures”. в: *Electronics* 8 (март 2019), с. 292. DOI: [10.3390/electronics8030292](https://doi.org/10.3390/electronics8030292).
- [2] Vyacheslav Demin и Dmitry Nekhaev. “Recurrent Spiking Neural Network Learning Based on a Competitive Maximization of Neuronal Activity”. в: *Frontiers in Neuroinformatics* 12 (нояб. 2018), с. 79. DOI: [10.3389/fninf.2018.00079](https://doi.org/10.3389/fninf.2018.00079).
- [3] Dmitry Nekhaev и Vyacheslav Demin. “Competitive Maximization of Neuronal Activity in Convolutional Recurrent Spiking Neural Networks”. в: янв. 2020, с. 255—262. ISBN: 978-3-030-30424-9. DOI: [10.1007/978-3-030-30425-6\\_30](https://doi.org/10.1007/978-3-030-30425-6_30).
- [4] Daniel J. Saunders и др. *Locally Connected Spiking Neural Networks for Unsupervised Feature Learning*. 2019. arXiv: [1904.06269](https://arxiv.org/abs/1904.06269) [cs.NE].
- [5] Li Wan и др. “Regularization of Neural Networks using DropConnect”. в: *Proceedings of the 30th International Conference on Machine Learning*. под ред. Sanjoy Dasgupta и David McAllester. т. 28. Proceedings of Machine Learning Research 3. Atlanta, Georgia, USA: PMLR, 17–19 Jun 2013, с. 1058—1066. URL: <http://proceedings.mlr.press/v28/wan13.html>.