

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА»

ФИЗИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА ОБЩЕЙ ФИЗИКИ И МОЛЕКУЛЯРНОЙ ЭЛЕКТРОНИКИ

**«МОДЕЛИРОВАНИЕ РАСПОЗНАВАНИЯ ОБРАЗОВ НА
ОСНОВЕ ИМПУЛЬСНЫХ НЕЙРОННЫХ СЕТЕЙ С
КОНКУРЕНЦИЕЙ ЛОКАЛЬНЫХ РЕЦЕПТИВНЫХ ПОЛЕЙ»**

Выполнил студент:
406 группа
Гафни Д.

Научный руководитель:
Королёва А.В.

Научный консультант:
Дёмин В.А.

Москва
2020

Содержание

| | | |
|----------|---|----------|
| 1 | Описание проблемы | 2 |
| 2 | Постановка задачи | 2 |
| 3 | Спайковые нейронные сети | 3 |
| 4 | Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей | 3 |
| 4.1 | Описание задачи классификации | 3 |
| 4.2 | Особенности архитектуры | 3 |
| 4.3 | Обучение связей спайковой нейронной сети | 3 |
| 4.4 | Обучение связей XU | 4 |
| 4.4.1 | Интерпретация активности спайковой нейронной сети | 4 |
| 4.5 | Сравнение эффективности операции свертки и локального рецептивного поля | 5 |
| 4.6 | Обучение связей UU (конкуренции) | 6 |
| 5 | Выводы | 6 |

1 Описание проблемы

Импульсные (спайковые) нейронные сети (СНС) являются перспективным нейроморфным алгоритмом, биологически корректно моделируя взаимодействия нейронов мозга. Наибольший интерес СНС представляют для решения задач в реальном времени (принятие решений, распознавание образов), так как при аппаратной реализации на специализированном нейрочипе обладают очень высокой энерго- и вычислительной эффективностью.

Современные формальные нейронные сети отлично справляются со многими задачами машинного обучения [1]. Однако их обучение - трудоемкий процесс, требующий больших вычислительных ресурсов [2]. Обучение СНС имеют многие преимущества перед обучением формальных нейронных сетей. Стандартные методы обучения весов связей, применяющиеся в формальных нейронных сетях (метод обратного распространения ошибки) не представляется возможным применять к СНС из-за их дискретной и распределенной во времени природы. Однако, в СНС могут применяться локальные правила обучения (STDP), не использующие при вычислениях информацию о глубоких слоях сети, а также способные к обучению без учителя. Таким образом, исследование алгоритмов обучения СНС представляется важной задачей.

2 Постановка задачи

В данной работе:

1. Изучается влияние обучения связей конкуренции [3] [4] между нейронами на точность распознавания образов в задаче классификации рукописных изображений цифр (MNIST) при обучении без учителя для архитектуры локально соединенной сети (Locally Connected Spiking Neural Network, LCSNN) [5]
2. Проводится сравнение этой архитектуры со сверточной сетью (Convolution Spiking Neural Network, CSNN) и полносвязной сетью (Fully Connected Spiking Neural Network, FCSNN).

3 Спайковые нейронные сети

Спайковая нейронная сеть [6] - модель нейронной сети, элементами которой являются отдельные нейроны и связи между ними. Каждый нейрон имеет свой виртуальный потенциал, а каждая связь имеет некоторый вес. Нейроны обмениваются дискретными электрическими сигналами (спайками), имеющими очень короткую (≈ 1 мс) длительность. Входящий спайк носит название *пре-спайка*, а исходящий - *пост-спайка*. Влияние пре-спайков на потенциал нейрона определяется значением веса межнейронной связи. При накоплении потенциала, превышающего определенный порог активации, нейрон сам испускает пост-спайк, а после сбрасывает свое напряжение до некоторого уровня релаксации. При запуске сети активность некоторых входных нейронов задается определенным образом, после чего проводится симуляция на протяжении некоторого времени (≈ 250 мс), много большего длительности спайка.

4 Моделирование обучения спайковой нейронной сети с конкуренцией локальных рецептивных полей

4.1 Описание задачи классификации

Для работы была выбрана классическая задача машинного обучения - задача классификации изображений рукописных цифр из набора данных [MNIST](#). MNIST состоит из размеченных обучающей и тестовых выборок объемами 60000 и 10000 изображений. Изображения имеют размер 28x28 пикселей и являются черно-белыми. Из-за необходимости калибровки сетей (4.4.1) обучающая выборка была разбита на 50000 изображений для обучения (обучающая выборка) и 10000 изображений для калибровки (калибровочная выборка).

В этой работе изображения обрезаются так, что используется только центральная область 20x20 пикселей.



Рис. 1: Изображения MNIST

4.2 Особенности архитектуры

Нейросетевая архитектура LCSNN [5] вдохновлена строением зрительной коры мозга. В отличие от сверточной сети, ее нейроны не имеют общих весов, которые потому и называются локальными.

Нейроны, имеющие общие рецептивные поля, соединяются связями конкуренции. Такие связи имеют отрицательные веса, а значит, негативно влияют на активность нейрона. Заметим, что нейроны, не имеющие общего рецептивного поля (а значит, реагирующие на разные области изображения) не конкурируют между собой.

4.3 Обучение связей спайковой нейронной сети

Для обучения сетей в этой работе используется правило STDP [7]. Согласно этому правилу обучения, также имеющему биологические аналоги, связь между нейронами усиливается, если пост-спайк этой связи часто случается после пре-спайка, и ослабевает, если происходит обратное.




Рис. 2: Архитектура LCSNN

4.4 Обучение связей XU

При обучении связей XU используется нормализация - после каждой итерации обучения веса каждого нейрона U слоя нормируются так, чтобы их сумма оставалась постоянной. Это позволяет весам сходиться в ограниченные значения.

Было обнаружено, что точность сети сильно зависит от параметра нормализации - среднего веса нейрона U слоя, достигая максимума на определенном значении от 0 до 1 в зависимости от конфигурации сети. Поэтому для каждой архитектуры производился поиск наилучшего значения параметра нормализации.

4.4.1 Интерпретация активности спайковой нейронной сети

Для интерпретации активности нейронов U слоя сети использовалось несколько методов.


Калибровка голосов Для первых трех методов необходимо произвести калибровку голосов нейронов. Каждому нейрону U слоя ставится в соответствие 10 чисел (голосов) для каждого возможного класса цифр (от 0 до 9). Голос вычисляется как среднее число спайков данного нейрона в ответ на демонстрацию сети данной цифры. Для всех сетей использовалась калибровка на 10000 примерах из калибровочной выборки. Заметим, что калибровка не является частью обучения сети, так как она входит лишь в алгоритм интерпретации поведения сети. Эти голоса используются как мера уверенности нейрона в каждом из классов. После демонстрации изображения сети подсчитывается общее количество спайков для каждого нейрона U слоя. Далее *результатом* будем называть произведение количества спайков нейрона на голос.

Общее голосование Ответом сети считается класс с максимальным *результатом* среди всех нейронов.

Голосование патчей Для каждого рецептивного поля ищется нейрон с максимальным *результатом*. Ответом сети считается класс с максимальным *результатом* среди этих нейронов.


Отбор по спайкам Для каждого рецептивного поля ищется нейрон с максимальным количеством спайков. Ответом сети считается класс с максимальным *результатом* среди этих нейронов.

Линейный классификатор Суммы спайков нейронов U слоя используются для обучения линейного классификатора. Для обучения классификатора также используется калибровочная выборка.



(a) Веса перед обучением (b) Веса после обучения

Рис. 3: Визуализация весов XU связей. Каждый квадратик соответствует весам одного U нейрона.



(a) Голоса нейронов U слоя.



(b) Среднее (по нейронам) значение голоса по значимости класса

Рис. 4: Визуализация голосов нейронов U слоя. Высокие значения соответствуют большой специализации.

Оценка алгоритма интерпретации Для оценки работы алгоритма интерпретации используется точность - отношение количества верно распознанных цифр к размеру тестовой выборки. В этой работе во всех случаях размер тестовой выборки составляет 10000. Отметим, что наличие сильной конкуренции позволяет даже слабо обученной сети иметь довольно высокую точность даже без обучения.

4.5 Сравнение эффективности операции свертки и локального рецептивного поля

Были проведены эксперименты по измерению точности сетей с различными архитектурами. Из-за очень высоких вычислительных нагрузок не ставилось задачи по нахождению параметров, идеально обеспечивающих максимальную точность для каждой архитектуры. Эти параметры были подобраны приблизительно, поэтому могли не попасть в максимум точности, однако величина расхождения не превышает 1-2%. Было протестировано несколько конфигураций для локально соединенных и для сверточных сетей, а также произведено сравнение со стандартной полносвязной сетью (также имеющей связи конкуренции). Видно, что локально соединенная сеть превосходит сверточную по точности при одинаковом числе нейронов (сравнивается количество нейронов Y слоя).




Рис. 5: LCSNN отличаются большой скоростью обучения. Через несколько тысяч итераций точность распознавания выходит на плато насыщения, после чего уже не возрастает. Видно, что три метода голосования в целом не отличаются по точности, а линейный классификатор значительно превосходит их все.

Таблица 1: Результаты сравнения различных архитектур спайковых нейронных сетей. Для каждой сети точность измерялась $N = 5$ раз. В таблице указаны средние значения и стандартное отклонение для точности.

*Конфигурация с обучаемой конкуренцией

| Архитектура | Каналы | Ядро | Веса | Нейроны | Точность, % |
|-------------|--------|------|--------|---------|----------------|
| LCSNN | 100 | 12 | 449100 | 900 | 87.5 ± 0.9 |
| LCSNN | 100 | 8 | 798400 | 1600 | 82.9 ± 0.2 |
| *LCSNN | 25 | 12 | 95400 | 225 | 82.3 ± 1.0 |
| LCSNN | 25 | 12 | 95400 | 225 | 80.1 ± 1.0 |
| LCSNN | 25 | 8 | 169600 | 400 | 73.6 ± 1.0 |
| CSNN | 100 | 8 | 11350 | 1600 | 77.4 ± 1.9 |
| CSNN | 25 | 12 | 3900 | 225 | 65.8 ± 0.7 |
| CSNN | 25 | 8 | 1900 | 400 | 58.1 ± 1.2 |
| FCSNN | 100 | 20 | 44950 | 100 | 73.4 ± 0.8 |

Отметим, что для локально соединенной сети из 100 каналов была получена точность 95% с использованием линейного классификатора.

Приведенные выше результаты согласуются с данными других исследований. Получение наиболее высокой точности не является целью данной работы. Тем не менее, даже однослой-

ная локально соединенная сеть позволяет добиться высокой точности, сравнимой со state of the art [8].

4.6 Обучение связей YU (конкуренции)

Связи YU очень сильно влияют на обучение связей XU . Большие по модулю значения способствуют вариативности в обучении Y нейронов, так для каждого рецептивного поля одновременно активными не могут быть нейроны, имеющие схожие веса XU , а малые по модулю значения не позволяют нейронам специализироваться.

Все сети до этого момента имели фиксированные веса конкуренции. Было обнаружено, что обучение весов конкуренции позволяет повысить точность сети. При помощи варьирования параметров STDP были получены различные распределения весов конкуренции.


Видно, что точность сети повышается при тяготении распределения весов конкуренции в сторону больших по модулю значений. Заметим, что целью являлось не нахождение параметров сети, обеспечивающих максимальную точность, а исследования влияния обучения или не-обучения конкуренции на точность сети с данной конфигурацией остальных параметров.

Примечательно, что не все связи YU получают большие по модулю значения. Это объясняется тем, что нейроны, специализирующиеся на значительно разных элементах, не нуждаются в конкуренции, так как они не проявляют высокую активность одновременно.

5 Выводы

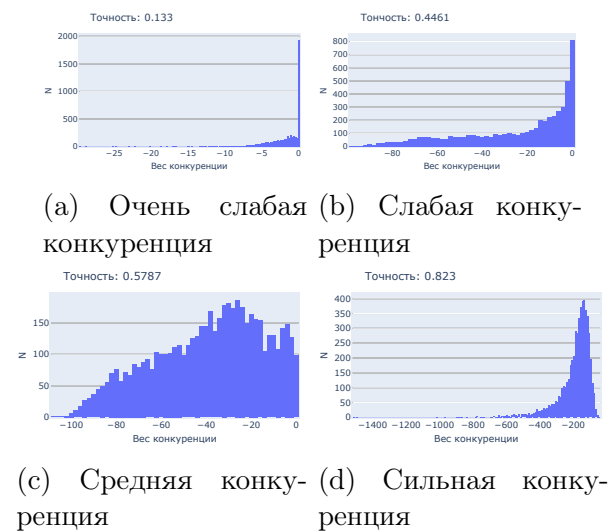
В результате проведения работы было проведено сравнение локально соединенной сети, сверточной сети и полносвязной сети. Локально соединенная сеть превосходит остальные архитектуры по точности, но имеет значительно больше параметров. Так как локально соединенная сеть хорошо масштабируется - ее точность монотонно возрастает при увеличении числа каналов [5], то эта архитектура является перспективной в аппаратной реализации. Обучение связей конкуренции этой сети в перспективе позволит добиться еще более высокой точности.

В качестве дополнительных перспектив развития отметим возможность исследования сетей с большим количеством каналов, более глубоких сетей (с большим количеством слоев) и изучение возможности реализации данных алгоритмов обучения СНС на основе мемристоров.



(а) Слабо специализированные веса, вес конкуренции равен -10 (б) Специализированные веса, вес конкуренции равен -100

Рис. 6: Влияние конкуренции на обучение XU связей



(а) Очень слабая конкуренция (б) Слабая конкуренция (с) Средняя конкуренция (д) Сильная конкуренция

Рис. 7: Различные распределения весов конкуренции

Список литературы

- [1] Li Wan и др. “Regularization of Neural Networks using DropConnect”. в: *Proceedings of the 30th International Conference on Machine Learning*. под ред. Sanjoy Dasgupta и David McAllester. т. 28. Proceedings of Machine Learning Research 3. Atlanta, Georgia, USA: PMLR, 17–19 Jun 2013, с. 1058–1066. URL: <http://proceedings.mlr.press/v28/wan13.html>.
- [2] Md. Zahangir Alom и др. “A State-of-the-Art Survey on Deep Learning Theory and Architectures”. в: *Electronics* 8 (март 2019), с. 292. DOI: [10.3390/electronics8030292](https://doi.org/10.3390/electronics8030292).
- [3] Vyacheslav Demin и Dmitry Nekhaev. “Recurrent Spiking Neural Network Learning Based on a Competitive Maximization of Neuronal Activity”. в: *Frontiers in Neuroinformatics* 12 (нояб. 2018), с. 79. DOI: [10.3389/fninf.2018.00079](https://doi.org/10.3389/fninf.2018.00079).
- [4] Dmitry Nekhaev и Vyacheslav Demin. “Competitive Maximization of Neuronal Activity in Convolutional Recurrent Spiking Neural Networks”. в: янв. 2020, с. 255–262. ISBN: 978-3-030-30424-9. DOI: [10.1007/978-3-030-30425-6_30](https://doi.org/10.1007/978-3-030-30425-6_30).
- [5] Daniel J. Saunders и др. *Locally Connected Spiking Neural Networks for Unsupervised Feature Learning*. 2019. arXiv: [1904.06269](https://arxiv.org/abs/1904.06269) [cs.NE].
- [6] Jesus L. Lobo и др. “Spiking Neural Networks and online learning: An overview and perspectives”. в: *Neural Networks* 121 (2020), с. 88–100. ISSN: 0893-6080. DOI: <https://doi.org/10.1016/j.neunet.2019.09.004>. URL: <http://www.sciencedirect.com/science/article/pii/S0893608019302655>.
- [7] Henry Markram, Wulfram Gerstner и Per Jesper Sjöström. “A History of Spike-Timing-Dependent Plasticity”. в: *Frontiers in Synaptic Neuroscience* 3 (2011), с. 4. ISSN: 1663-3563. DOI: [10.3389/fnsyn.2011.00004](https://doi.org/10.3389/fnsyn.2011.00004). URL: <https://www.frontiersin.org/article/10.3389/fnsyn.2011.00004>.
- [8] Amirhossein Tavanaei и Anthony Maida. “Multi-Layer Unsupervised Learning in a Spiking Convolutional Neural Network”. в: май 2017. DOI: [10.1109/IJCNN.2017.7966099](https://doi.org/10.1109/IJCNN.2017.7966099).